

Diffusion U-Net 內部表徵之可解釋性分析

應用於台灣高解析度降雨降尺度

研究構想、XAI 方法與相關文獻整理

1 研究動機

本研究使用conditional diffusion model 進行台灣降雨降尺度。目前模型可以根據低解析度atmospheric conditions 生成高解析度precipitation prediction，但模型內部如何將氣象資訊轉換成降雨correction，仍然缺乏直接且可解釋的分析。

因此，本研究不只希望回答：

「哪一個atmospheric input variable 比較重要？」

而是進一步研究：

Diffusion U-Net 的不同layer、channel 與denoising timestep 到底形成了什麼internal representation？這些latent features 是否與可解釋的氣象條件、降雨型態與precipitation correction 有關？

整體研究概念可整理為：

Diffusion U-Net → Internal Representation → Physical Interpretation → Causal Validation

2 目前模型

目前模型的conditioning input 包含六個動態氣象變數：

$$q700, \quad t2m, \quad u, \quad v, \quad msl, \quad tp$$

以及land mask，共七個conditioning channels。

原始coarse grid 為：

$$14 \times 9,$$

經interpolation 轉換到target grid：

$$112 \times 72.$$

模型並不是直接預測rainfall，而是學習high-resolution truth 與coarse precipitation 之間的log-space residual：

$$r = \log(1 + P_{\text{fine}}) - \log(1 + P_{\text{coarse}}).$$

再經normalization 得到：

$$r_{\text{norm}}.$$

Training 時對clean residual 加入Gaussian noise：

$$x_\sigma = r_{\text{norm}} + \sigma \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

因此U-Net spatial input 共有：

$$1 + 7 = 8$$

個channels，其中：

- 1 個noisy precipitation residual；
- 7 個atmospheric conditioning channels。

3 Diffusion U-Net 架構

目前U-Net 的主要channel flow 為：

$$8 \rightarrow 128 \rightarrow 256 \rightarrow 384 \rightarrow 512 \rightarrow 384 \rightarrow 256 \rightarrow 128 \rightarrow 1.$$

Encoder spatial resolution 依序為：

$$112 \times 72 \rightarrow 56 \times 36 \rightarrow 28 \times 18 \rightarrow 14 \times 9.$$

最深層latent representation 約為：

$$F_{\text{middle}} \in \mathbb{R}^{512 \times 14 \times 9}.$$

主要U-Net block 可以概念化為：

$$\boxed{\text{GroupNorm} \rightarrow \text{SiLU} \rightarrow \text{Conv} \rightarrow \text{Conditioning} \rightarrow \text{Conv} \rightarrow \text{Residual}}$$

其中noise level、year 與day-of-year 會先形成embedding，再透過scale 與shift 調整block features。

Bottleneck 另外具有self-attention：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V.$$

因此可解釋性分析不只可以看最終prediction，也可以直接分析：

$$\boxed{\text{Encoder} + \text{Middle} + \text{Decoder} + \text{Attention} + \text{Diffusion Timestep}}$$

4 核心研究問題

本研究主要考慮以下問題：

1. **Layer-wise representation**：不同U-Net layers 是否學習不同尺度的precipitation information？
2. **Timestep-wise representation**：不同diffusion timesteps 中，latent representation 是否隨denoising 過程逐漸改變？
3. **Channel specialization**：是否存在只對特定precipitation regime、weather event 或atmospheric condition 具有較強activation 的latent channels？

4. **Physical association** : latent features 是否與precipitation intensity、moisture、wind、terrain 或其他atmospheric information 具有穩定關聯？
5. **Causal role** : 若移除或修改selected latent features，model prediction 是否會在固定random seed 下穩定改變？

5 XAI 方法一：Internal Activation Extraction

在diffusion inference 過程中，記錄不同U-Net layer 的activation：

$$F_{d,m,t,l} \in \mathbb{R}^{C_l \times H_l \times W_l},$$

其中：

- d : date / weather event ;
- m : ensemble member ;
- t : diffusion timestep ;
- l : U-Net layer °

例如bottleneck：

$$F_{d,m,t,\text{middle}} \in \mathbb{R}^{512 \times 14 \times 9}.$$

第一版可以先分析：

- Deep Encoder ;
- Middle / Bottleneck ;
- Middle Decoder ;
- Late Decoder °

實作上可使用PyTorch forward hook，在不改變原始network forward calculation 的情況下，記錄selected layer activations °

6 XAI 方法二：Channel Analysis

假設某一層activation：

$$F \in \mathbb{R}^{C \times H \times W}.$$

對每個channel 做spatial average：

$$\phi_c = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W F_{c,i,j}.$$

因此：

$$F \rightarrow \phi \in \mathbb{R}^C.$$

例如bottleneck：

$$512 \times 14 \times 9 \rightarrow 512.$$

可以進一步分析：

- Top activated channels；
- Top activating weather events；
- Heavy rain 與normal rain 的activation difference；
- 不同season 的representation difference；
- 不同precipitation regimes 的channel profiles。

但必須注意：

高activation 只能表示association，不能直接宣稱某個channel 就代表單一物理現象。

單一neural channel 仍可能是polysemantic，也就是同時混合多種資訊。

7 XAI 方法三：PCA 與Similarity

若共有 N 個weather events，將每個event 的channel representation 組成：

$$\Phi \in \mathbb{R}^{N \times C}.$$

可以使用PCA：

$$\mathbb{R}^C \rightarrow \mathbb{R}^2.$$

例如：

$$512D \rightarrow 2D.$$

再依：

- rainfall intensity；
- season；
- weather event type；
- atmospheric regime

進行視覺化。

也可以計算cosine similarity：

$$\text{sim}(a, b) = \frac{\phi_a^T \phi_b}{\|\phi_a\| \|\phi_b\|}.$$

藉此分析：

相似precipitation events 是否在neural latent space 中也形成相似representations？

8 XAI 方法四：Diffusion Timestep Analysis

Diffusion 與一般CNN 最大的差異之一是：

$$\text{Representation} = \text{Layer} \times \text{Timestep}$$

因此不應只分析某一個固定U-Net layer，也應分析feature 隨iterative denoising 的變化。

第一版可以選擇：

$$t \in \{0, 5, 15, 30, 39\}.$$

對同一個weather event 比較：

$$F_{l,0}, \quad F_{l,5}, \quad F_{l,15}, \quad F_{l,30}, \quad F_{l,39}.$$

可以分析：

$$\text{sim}(\phi_t, \phi_{t+1})$$

或利用PCA 顯示representation trajectory。

主要問題為：

Atmospheric structure 與fine-scale precipitation correction 是在denoising 的哪一個階段逐漸形成？

這裡的「何時形成」必須由實驗驗證，不能預先假設高noise 一定只代表大尺度、低noise 一定只代表小尺度。

9 XAI 方法五：Spatial Feature Map

對單一channel：

$$F_c \in \mathbb{R}^{H \times W},$$

可以resize 至：

$$112 \times 72,$$

再與以下資料比較：

- Ground Truth；
- Coarse precipitation；
- Prediction；
- Prediction minus Coarse；
- Elevation；
- Land mask。

模型實際產生的precipitation correction 可以定義為：

$$\Delta P = P_{\text{prediction}} - P_{\text{coarse}}.$$

因此可以分析：

$$\text{corr}(F_c, \Delta P).$$

與直接拿feature 和truth 做correlation 相比， ΔP 更直接對應目前residual-based diffusion model 真正需要學習的correction。

10 XAI 方法六：Feature Probing

利用frozen latent representation：

$$\phi_l$$

訓練簡單的linear probe。

例如Heavy Rain Classification：

$$\hat{y} = \sigma(w^T \phi_l + b).$$

比較不同layer 的：

$$AUC_l.$$

如果middle layer 的AUC 較高，代表heavy-rain information 在該representation 中較容易被線性解碼。

也可利用Linear Regression：

$$\hat{y} = w^T \phi + b$$

預測：

- precipitation intensity；
- q700；
- regional rainfall；
- 其他可量化atmospheric variables。

並使用：

$$R^2$$

評估representation 中包含多少可被線性解碼的資訊。
但必須注意：

Probe 能讀出資訊，不代表模型一定依賴該資訊完成prediction。

因此仍需要causal intervention。

11 XAI 方法七：Causal Intervention

假設找到candidate channel：

$$F_c.$$

可以進行channel ablation：

$$F'_c = 0.$$

或者scaling：

$$F'_c = \alpha F_c.$$

例如：

$$\alpha \in \{0, 0.5, 1, 2\}.$$

接著比較：

$$\Delta P = P_{\text{original}} - P_{\text{intervention}}.$$

也可以計算：

$$\Delta MAE = MAE_{\text{intervention}} - MAE_{\text{original}}.$$

若某個selected feature 被移除後，特定precipitation region 穩定產生明顯變化，而matched control channels 沒有相同效果，則可以提供比correlation 更强的mechanistic evidence。

除了zero ablation，亦可考慮：

- mean replacement；
- channel scaling；
- group ablation；
- matched random-channel controls。

以降低單純使用zero ablation 造成out-of-distribution activation 的疑慮。

12 固定Seed 的重要性

Diffusion inference 本身具有stochasticity。

因此intervention experiment 必須固定：

- same date；
- same atmospheric input；
- same checkpoint；
- same seed；
- same ensemble member；
- same sampling steps；

- same sigma schedule ;
- same sampler parameters °

唯一修改：

$$F_c.$$

如此：

$$P_{\text{original}} - P_{\text{intervention}}$$

才比較可以反映feature intervention effect，而不是不同random sampling trajectory 造成的差異。

13 相關研究與本研究關係

目前與本研究最相關的文獻可以分成三條路線。

A. Diffusion Internal Representation

這類工作研究diffusion denoiser 的internal activations 是否本身包含有意義的representation。

Kadkhodaie et al. 直接分析denoising U-Net middle block，指出個別輸入只會強烈啟動部分channels，而channel 的spatial-average vector 能形成有意義的internal representation。

Meng et al. 則指出diffusion model 中可以分析的activation 不只一般block output，還包括attention 中的query、key 等訊號，因此不能預設單一block 一定是最佳feature。

Diffusion Hyperfeatures 進一步指出：diffusion representation 同時分布於不同network layers 與不同denoising timesteps。

因此本研究採用：

$$\boxed{\text{Layer} \times \text{Channel} \times \text{Timestep}}$$

作為internal representation 的主要分析框架。

B. Diffusion Mechanistic Interpretability

這類研究不只觀察activation，也透過internal feature manipulation 或controlled intervention 驗證feature 是否具有causal role。

Revelio 利用k-Sparse Autoencoder 找出較sparse、較容易解釋的diffusion features。

Maliha and Hougén 則透過fixed-seed counterfactual intervention 分析diffusion denoising mechanism，其中「保持sampling seed 固定」的實驗設計對本研究非常重要。

C. Weather Physical Interpretability

Weather AI 領域開始研究neural network internal latent representation 是否能對應氣象現象。

Tempest et al. 利用PCA 與cosine similarity 分析GraphCast latent space，尋找可能對應synoptic-scale waves 與humidity 的latent directions。

MacMillan and Ouellette 則使用Sparse Autoencoder 研究GraphCast internal activations，找到與tropical cyclones、atmospheric rivers、precipitation patterns 等現象相關的latent features，並進一步進行internal intervention。

另一方面，Lee and Shamekh 的precipitation diffusion downscaling 已經使用perturbation-based feature importance 分析模型對atmospheric predictors 的context-dependent reliance 。因此本研究希望從input-level physical interpretability 再往模型內部推進：

Atmospheric Input $\rightarrow$ U-Net Internal Representation $\rightarrow$ Precipitation Correction

14 最小可行實驗

第一版建議先控制研究規模，不需要一次分析所有layers、timesteps 與ensemble members 。

1. 選三個代表layers：

DeepEncoder, Middle, LateDecoder.

2. 選五個diffusion steps：

0, 5, 15, 30, 39.

3. 挑選不同precipitation cases：

- heavy rain；
- moderate rain；
- light rain；
- dry cases；
- different seasons 。

4. 先做三種descriptive analysis：

ChannelMean, PCA, SpatialMap.

5. 找candidate latent channels 。

6. 進行simple feature probing 。

7. 最後對selected features 做fixed-seed channel ablation 。

15 建議量化指標

除了視覺化之外，建議至少包含以下quantitative measurements：

- **Activation sparsity**

$$S_l = \frac{\#(|F_l| < \epsilon)}{\#F_l}.$$

- Cosine similarity

$$\text{sim}(a, b) = \frac{\phi_a^\top \phi_b}{\|\phi_a\| \|\phi_b\|}.$$

- Physical correlation

$$\text{corr}(F_c, \Delta P).$$

- Probe performance

$$AUC, \quad R^2.$$

- Intervention effect

$$\Delta P = P_{\text{original}} - P_{\text{intervention}}.$$

- Skill degradation

$$\Delta MAE = MAE_{\text{intervention}} - MAE_{\text{original}}.$$

16 建議論文圖表

若實驗完成，可考慮以下figures：

1. Diffusion U-Net architecture 與XAI hook positions；
2. Encoder / Middle / Decoder representation PCA；
3. 同一事件不同diffusion timesteps 的latent trajectory；
4. selected latent channel spatial maps；
5. Top activating weather events；
6. latent feature 與atmospheric variables 的association；
7. Original prediction、Ablated prediction 與Difference map；
8. Layer $\times$ Timestep interpretability matrix。

17 研究定位與可能貢獻

本研究與一般input-level XAI 的最大差異是：

Input Importance $\neq$ Internal Mechanism
--

本研究希望進一步研究：

Layer $\times$ Channel $\times$ Diffusion Timestep
--

如何形成internal representations，並將其連結到：

Atmospheric Physics + Precipitation Correction

若實驗結果成立，可能形成以下研究貢獻：

1. 系統分析precipitation diffusion U-Net 在不同layers 的internal representations；
2. 分析latent representations 隨iterative denoising timestep 的演化；
3. 找出與atmospheric conditions 或precipitation regimes 有關的latent features；
4. 使用fixed-seed causal intervention 驗證selected internal features 對precipitation prediction 的實際影響。

最終核心研究問題可以寫成：

How do physically meaningful representations emerge and evolve across layers and denoising timesteps inside a conditional diffusion U-Net for precipitation downscaling?

18 研究限制

在解讀XAI 結果時必須避免以下過度結論：

- Correlation 不等於causation；
- 單一neural channel 可能是polysemantic；
- PCA component 不等於真實物理變數；
- Attention weight 不等於完整causal explanation；
- Zero ablation 可能形成out-of-distribution activation；
- Probe 可以解碼資訊，不表示model 一定使用該資訊；
- Diffusion intervention 必須控制random seed 與sampler configuration。

因此較嚴謹的證據鏈應為：

Observation → Statistical Association → Probe → Controlled Intervention

19 參考文獻與重點

1. Diffusion U-Net Internal Representation

Kadkhodaie, Mallat, and Simoncelli, “Elucidating the Representation of Images within an Unconditional Diffusion Model Denoiser,” 2025.

- [\[PDF\]](#)
- [\[arXiv Page\]](#)

- **重點：** 直接研究diffusion denoising U-Net 的internal representation。作者指出middle block 會將個別image 表成較sparse 的active-channel subset，而spatially averaged channel activations 可以形成有意義的latent representation。
- **與本研究關係：** 可直接參考：

$$[512, 14, 9] \rightarrow [512]$$

的channel spatial-average analysis，再找top activated channels 與top activating weather cases。

2. Diffusion Activation Selection

Meng et al., “Not All Diffusion Model Activations Have Been Evaluated as Discriminative Features,” NeurIPS 2024.

- [\[PDF\]](#)
- [\[arXiv Page\]](#)
- [\[Code\]](#)
- **重點：** 系統研究diffusion backbone 中不同activations 作為discriminative features 的能力，並強調query、key 等attention internal signals 也值得分析。
- **與本研究關係：** 提供layer selection 的方法論依據；不能預設bottleneck 一定最佳，而應比較Encoder、Middle 與Decoder。

3. Layer × Timestep Representation

Luo et al., “Diffusion Hyperfeatures: Searching Through Time and Space for Semantic Correspondence,” NeurIPS 2023.

- [\[PDF\]](#)
- [\[Paper Page\]](#)
- **重點：** Diffusion feature 同時分布在不同network layers 與不同denoising timesteps。
- **與本研究關係：** 直接支撐：

$$\boxed{\text{Layer} \times \text{Timestep}}$$

的分析設計，例如比較step 0, 5, 15, 30, 39 的latent evolution。

4. Sparse and Interpretable Diffusion Features

Kim, Thomas, and Ghadiyaram, “Revelio: Interpreting and Leveraging Semantic Information in Diffusion Models,” ICCV 2025.

- [\[PDF\]](#)
- [\[Paper Page\]](#)
- [\[Code\]](#)
- **重點：** 研究不同diffusion architectures 的layer- and timestep-dependent representations，並使用k-Sparse Autoencoder 尋找較sparse、較接近monosemantic 的features。
- **與本研究關係：** 若raw U-Net channels 過於polysemantic，可進一步使用SAE 將internal activation 分解成較容易解讀的latent concepts。

5. Diffusion Features as Dense Representation

Tang et al., “Emergent Correspondence from Image Diffusion,” NeurIPS 2023.

- [\[PDF\]](#)
- **重點：** Diffusion U-Net intermediate feature maps 即使沒有為correspondence task 進行supervision，仍可形成有用的dense representation。
- **與本研究關係：** 可將：

$$F(:, i, j)$$

視為某個spatial location 的latent descriptor，再利用cosine similarity 比較不同位置或不同weather events。

6. Spatial Features and Self-Attention

Tumanyan et al., “Plug-and-Play Diffusion Features for Text-Driven Image-to-Image Translation,” CVPR 2023.

- [\[PDF\]](#)
- [\[Paper Page\]](#)
- **重點：** 顯示diffusion U-Net 的spatial features 與self-attention 對生成spatial structure 有實際作用，並使用intermediate features 進行manipulation。
- **與本研究關係：** 可參考其spatial-feature / attention 分析思路，並延伸至precipitation feature maps。

7. Fixed-Seed Mechanistic Intervention

Maliha and Hougen, “Mechanistic Interpretability of Text-to-Image Diffusion Models via Cross-Attention Interventions,” Findings of ACL 2026.

- [\[PDF\]](#)
- [\[Paper Page\]](#)
- **重點：** 透過denoising cross-attention activation 與controlled prompt intervention 研究diffusion model 的internal mechanism，並在intervention 前後保持sampling seed 固定。
- **與本研究關係：** 雖然本模型沒有text cross-attention，但fixed-seed controlled intervention 可以直接轉成U-Net channel ablation：

$$F'_c = 0.$$

8. Mechanistic Interpretability for Weather Models

Tempest, Beylich, and Craig, “Mechanistic Interpretability Tool for AI Weather Models,” 2026.

- [\[PDF\]](#)
- [\[arXiv Page\]](#)
- **重點：** 建立分析AI weather model internal latent representation 的工具，利用PCA 與cosine similarity 尋找可能與meteorological features 對應的latent directions。
- **與本研究關係：** 提供從neural latent representation 連結到meteorological interpretation 的直接方法論參考。

9. Sparse Features in Weather Models

MacMillan and Ouellette, “Towards Mechanistic Understanding in a Data-Driven Weather Model: Internal Activations Reveal Interpretable Physical Features,” 2025.

- [\[PDF\]](#)
- [\[arXiv Page\]](#)
- **重點：** 使用Sparse Autoencoder 分析GraphCast internal activations，找出與tropical cyclones、atmospheric rivers、precipitation、seasonality、geography 等現象相關的latent features，並透過feature intervention 驗證其effect。
- **與本研究關係：** 完整示範：

Feature Discovery → Physical Interpretation → Intervention

的weather mechanistic interpretability pipeline。

10. Precipitation Diffusion + Physical Interpretability

Lee and Shamekh, “How Far Can We Downscale? Resolution Limits and Physical Interpretability of Diffusion Models for African Precipitation,” Machine Learning: Earth, 2026.

- [\[Open-Access Paper / PDF Page\]](#)
- **重點：** 使用conditional denoising diffusion model 進行Sub-Saharan Africa precipitation downscaling，比較deterministic convolutional baselines，並分析spatial variability、extreme-event distribution 與input-resolution limits。
- 作者使用perturbation-based feature importance 研究atmospheric predictor reliance，發現模型依賴的predictors 會隨terrain、season 與atmospheric regime 改變。
- **與本研究關係：** 這篇與本研究application 最接近：

Precipitation + Downscaling + Diffusion + Physical Interpretability.

但其重點較偏：

Input Predictor Importance.

本研究希望再往模型內部延伸：


Input $\rightarrow$ U-Net Internal Representation $\rightarrow$ Output

並分析：


Layer $\times$ Channel $\times$ Timestep.

20 文獻與本研究的整體關係

現有研究可整理成三條路線：



本研究希望整合三者：



因此，本研究不只分析模型「使用了哪些輸入」，而是進一步研究：

Atmospheric information 如何在conditional diffusion U-Net 的iterative denoising 過程中被轉換成internal representations，以及這些representations 是否真的參與high-resolution precipitation correction。